
MULTICHANNEL SOM WITH OPTICAL IMAGES

DATA SCIENCE PROJEKT

Dennis Imhof
Hochschule Darmstadt
dennis.imhof@stud.h-da.de

Simon Stevens
Hochschule Darmstadt
simon.stevens@stud.h-da.de

Jeremy Mah Zhee Kein
Hochschule Darmstadt
jeremy.kein@stud.h-da.de

Sara El-Beit Shawish
Hochschule Darmstadt
sara.shawish@stud.h-da.de

Negar Farjoud Masouleh
Hochschule Darmstadt
negar.masouleh@stud.h-da.de

08. Februar 2022

Inhaltsverzeichnis

1	Einleitung und Motivation	3
2	Grundlagen SOM	3
2.1	Input Layer	3
2.2	Output Layer	3
2.3	Training	4
2.3.1	Auswahl der Trainingsdaten	4
2.3.2	Kompetitiver Teil: Ähnlichkeitssuche / Best-Matching Unit	4
2.3.3	Kooperativer Teil: Nachbarschaft und Gewichtsupdate	5
2.3.4	Lernrate $\alpha(t)$	5
2.3.5	Nachbarschaftsfunktion $h_{c_i}(t)$	6
2.3.6	Konvergenz- / Abbruchkriterium	6
2.4	PINK - Parallelized Rotation- and Flipping-Invariant Kohonen Maps	6
3	Training	7
3.1	Datensätze	7
3.2	Vorverarbeitung der Bilder	7
3.2.1	Min-Max Skalierung	7
3.3	Parameter	7
3.4	Trainings mit Radio Bildern	7
3.5	Trainings mit Multichannel SOMs	7
3.5.1	Eingrenzung des optischen Channels durch Bounding Box	7
3.5.2	Eingrenzung des optischen Channels durch eine kovexe Hülle	7

3.5.3	Eingrenzung des optischen Channels auf minimalen Kreisausschnitt im Zentrum	7
3.5.4	Gewichtung der Channels	7
3.5.5	Eingrenzung des optischen Channels durch einen Kreisausschnitt basierend auf einer kovexen Hülle mit	7
4	Ergebnisse	7
4.1	Limitationen	7
4.2	Verbesserungsoptionen	7
5	Fazit	7

ABSTRACT

Aufgrund der großen Datenmengen durch aktuelle Himmelsdurchmusterungen gewinnt die Klassifikation mit Hilfe von Methoden des maschinellen Lernens an Bedeutung. Für die ausgedehnten Quellen in der ersten Veröffentlichung von Daten des LOFAR Two-Metre Sky Survey [1] hat sich die automatische Gruppierung der Quellmorphologien mit Hilfe der Self-Organising-Maps (SOMs) als sehr leistungsvoll erwiesen [2]. In diesem Beitrag wird gezeigt, wie diese Methode weiterentwickelt werden kann, um die morphologische Klassifikation von Radioquellen zu verbessern und die zugehörigen Wirtsgalaxien in optischen Karten [3] zu identifizieren. Hierzu werden 2-Kanal-Kohonenkarten mit Hilfe der PINK-Software [4] trainiert und anschließend analysiert. Durch das Setzen eines Begrenzungsrahmens wird die Anzahl der möglichen zugehörigen Wirtsgalaxien erheblich eingeschränkt. In weiteren Schritten werden andere Eigenschaften der Quellen, z.B. Rotverschiebung, zusätzlich in dem Lernverfahren berücksichtigt.

1 Einleitung und Motivation

Es gab in den letzten Jahren immer größere Datenerhebungen in Bezug auf beobachtbare Galaxien in unterschiedlichen Wellenlängenbereichen. Beispielsweise wurden im LOFAR Two-Metre Sky Survey (LOTSS) in der ersten Datenveröffentlichung über 44.000 ausgedehnte Quellen im Radiobereich detektiert [1]. In der zweiten Daten Veröffentlichung werden noch viel mehr solcher ausgedehnten Quellen erwartet. Eine Klassifikation solcher Quellen und insbesondere das aufspüren der entsprechenden Wirtsgalaxie im sichtbaren Wellenlängenbereich ist sehr aufwändig. Deshalb gewinnen Verfahren die eine solche Klassifikation automatisch machen immer mehr an Bedeutung. Das aufspüren und Klassifizieren von Radio Galaxien mittels Self Organizing Maps (SOMs) hat sich dabei schon in früheren Arbeiten als sehr erfolgreich herausgestellt [2].

In diesem Paper wird die Implementation der Parallelized Rotation- and Flipping-Invariant Kohonen Maps (PINK) [4] um einen optischen Channel erweitert. Die optischen Daten sind dabei aus dem PannSTARS Survey [3].

Ziel der Arbeit ist es die folgende Forschungsfrage zu beantworten. Eignen sich multichannel SOMs dazu Aussagen über die wahrscheinliche Position von Wirtsgalaxien im optisch sichtbaren Wellenlängenbereich zu machen?

2 Grundlagen SOM

Bei Self-Organizing Maps (SOMs) handelt es sich um neuronale Netzwerke mit zwei Ebenen / Layers, dem Input- und dem Output-layer. Bei dem Algorithmus handelt es sich um einen Unsupervised Learning Algorithmus und dabei konkret um ein Clustering. Hochdimensionale Daten sollen in einen niedriger dimensional Raum abgebildet werden, wie in der folgenden Illustration dargestellt.

2.1 Input Layer

Die Inputs \mathbf{x} des Netzwerks stellen m -dimensionale Vektoren dar.

$$\mathbf{x} = (x_1, x_2, \dots, x_m)^T$$

Dies können auch mehrdimensionale Strukturen (Tensoren, bspw. Bilder mit mehreren Farb-channels) sein, die in eine flache (*flattened*), m -dimensionale Vektorstruktur überführt werden. Bei großen Unterschieden in den Größenordnungen der Attributwerte des Vektors kann es Sinn machen, die Werte zu normalisieren oder hin zu einem vergleichbaren Wertebereich zu skalieren.

2.2 Output Layer

Das Output- oder auch SOM-Layer repräsentiert die Daten in reduzierter Dimensionalität bspw. als zweidimensionales Gitter aus $p \times q$ Output-Knoten. Die Menge der Output-Knoten ist damit also

$$W = \{w_1, \dots, w_{p \times q}\}$$

und ein Knoten w_i stellt dabei einen Vektor der Dimension m dar

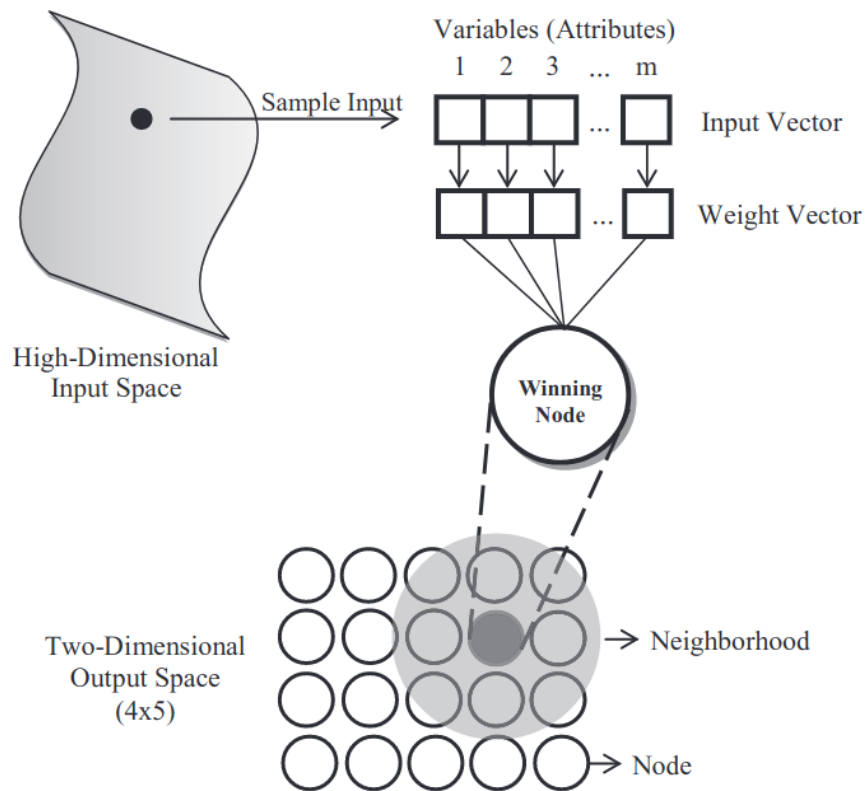


Abbildung 1: Übersicht Self-Organizing Map aus An Introduction to Self-Organizing Maps

$$\mathbf{w}_i = (w_{i1}, \dots, w_{im})^T$$

Die Output-Knoten sind typischerweise rechteckig oder hexagonal angeordnet, wobei jeder Output-Knoten einen Repräsentanten bestimmter Merkmalsausprägungen darstellt. Der Output-Knoten wird deshalb auch Prototyp genannt. Darüberhinaus sind sich benachbarte Knoten ähnlich bzw. sich ähnliche Prototypen sind benachbart angeordnet.

2.3 Training

Zu Beginn des Trainings werden die Output-Knoten mit kleinen Zufallswerten initialisiert. Es wird dann im Rahmen mehrerer Iterationen die Self-Organizing Map trainiert, wobei sich eine Trainingsiteration aus einem kompetitiven Teil, Wettbewerb um Best Matching Unit, und einem kooperativen Teil, Update der Best Matching Unit und Nachbarschaft, zusammensetzt.

2.3.1 Auswahl der Trainingsdaten

Eine Trainingsiteration t beginnt mit der zufälligen Auswahl eines Inputvektors $\mathbf{x}(t)$ aus den Trainingsdaten. Hierbei soll der Parameter ' t ' darstellen, dass es sich um irgendeinen Trainingsvektor ' $x_i \in \mathbf{X}$ ' zu Iteration ' t ' handelt.

2.3.2 Kompetitiver Teil: Ähnlichkeitssuche / Best-Matching Unit

Es wird zunächst die *Best-Matching Unit, BMU* gesucht. Es handelt sich hierbei um den Output-Knoten / Gewicht w_j , das dem Input-Vektor x_i am ähnlichsten ist und wird als $c(t)$ definiert.

Die Ähnlichkeit wird typischerweise mit der euklidischen Distanzfunktion beziffert. Man könnte auch ein anderes Distanzmaß verwenden, jedoch hat sich die euklidische Distanz als das am besten performende Maß herausgestellt.

Die *BMU* lässt sich mit folgender Vorschrift ermitteln:

$$c(t) = \min_i \{ ||\mathbf{x}(t) - w_i(t)|| \}$$

wobei $|| \cdot ||$ die euklidische Distanz darstellt ie.

$$||\mathbf{x}|| = \sqrt{\sum_{i=1}^n x_i^2}$$

2.3.3 Kooperativer Teil: Nachbarschaft und Gewichtsupdate

Wurde die *Best-Matching Unit*, $c(t)$, gefunden, werden diese und ihre Nachbarn derart upgedatet, dass sie dem aktuellen Inputvektor $x(t)$ etwas stärker ähneln. Das Gewichtsupdate der *BMU* und ihrer Nachbarschaft wird für die betroffenen Output-Knoten $w_i(t)$ gemäß folgender Vorschrift durchgeführt

$$w_i(t+1) = w_i(t) + \alpha(t) h_{ci}(t) [x(t) - w_i(t)]$$

Hierbei sind

- $x(t)$ - Zufällig ausgewählter Input-Vektor zu Iteration t
- $w_i(t)$ - Output-Knoten i
- $w_i(t+1)$ - Geupdateter Output-Knoten i
- $\alpha(t)$ - Von diskreter Zeit / Iteration t abhängige, monoton fallende Lernratenfunktion mit Wertebereich $\alpha \in [0, 1]$
- $h_{ci}(t)$ - Nachbarschaftsfunktion / Diskriminanzfunktion abhängig von *Best-Matching Unit* $c(t)$, betrachtetem Gewicht $w_i(t)$ und Iteration t

2.3.4 Lernrate $\alpha(t)$

Die Lernrate $\alpha(t)$ ist eine monoton fallende Funktion abhängig von Iteration t mit Wertebereich $\alpha \in [0, 1]$. Initial sollte ein relativ hoher Wert gewählt werden, sodass in der anfänglichen Ordnungsphase stärkere Veränderungen möglich gemacht werden. Durch das Abnehmen der Lernrate sollen zu starke Veränderungen zu einem späteren Zeitpunkt vermieden und nur noch Änderungen zur Verfeinerung der Map vorgenommen werden. Möglich sind zum Beispiel die lineare Funktion

$$\alpha(t) = \alpha(0) \frac{1}{t}$$

die inverse Funktion

$$\alpha(t, T) = \alpha(0) \cdot \left(1 - \frac{t}{T}\right)$$

oder die Potenzreihe

$$\alpha(t, T) = \alpha(0) \cdot e^{-\frac{t}{T}}$$

mit

- $t \in \mathbb{N}_+$ - Aktuelle Iteration
- T - Gesamtzahl an Iterationen

2.3.5 Nachbarschaftsfunktion $h_{c_i}(t)$

Als Nachbarschaftsfunktionen sind diskrete Funktionen, die bspw. bei rechteckiger Topologie ausschließlich die direkten 4 bzw. 8 Nachbarn miteinbeziehen oder auch stetige Funktionen wie der Gauß-Kernel möglich. Eine diskrete Nachbarschaftsfunktion $h_{i,j}^c$ lässt sich bspw. über die Menge der benachbarten Indizes N_c definieren. Die Koordinaten i, j sind dabei die Koordinaten im rechteckigen Gitter.

$$h_{i,j}^c(t) = \begin{cases} 1, & (i, j) \in N_c \\ 0, & (i, j) \notin N_c \end{cases}$$

Eine stetige Nachbarschaftsfunktion lässt sich bspw. durch einen Gauß-Kernel definieren. Diese Konfiguration wird auch in den PINK-Experimenten verwendet und ist im Folgenden beschrieben. In PINK wird eine Gaußfunktion verwendet, die mit zunehmender Iterationszahl einen kleineren Nachbarschaftsradius σ aufweist:

$$h_{c_i}(t) = \frac{1}{\sigma(t)\sqrt{2\pi}} \cdot \exp \left[-\frac{1}{2} \left(\frac{\|c(t) - w_i(t)\|}{\sigma(t)} \right)^2 \right]$$

2.3.6 Konvergenz- / Abbruchkriterium

Es kann eine feste Anzahl an Iterationen oder ein minimales Delta der Gewichtsupdates als Abbruchkriterium festgelegt werden.

2.4 PINK - Parallelized Rotation- and Flipping-Invariant Kohonen Maps

PINK [4] stellt eine Erweiterung des zuvor beschriebenen Self-Organizing Map Algorithmus dar. Hierbei werden parallelisiert multiple rotations- und flip-transformierte Abbildungen eines zweidimensionalen Inputbildes erstellt und die Best Matching Unit bezüglich aller Output-Knoten und aller transformierten Abbildungen gesucht. Da die Transformationen unabhängig voneinander sind, lässt sich jener Vorverarbeitungsschritt parallelisiert (bspw. auf GPU-Hardware) durchführen, was in einer erheblichen Beschleunigung gegenüber einer sequenziellen Verarbeitung resultiert.

Die im Rahmen dieser Arbeit verwendeten Inputdaten, zentrierte Bilder von Radiogalaxien, lassen sich mithilfe der beschriebenen Vorverarbeitungsschritte rotations- und spiegelinvariant clustern.

Die Lernrate in PINK wurde folgendermaßen gewählt:

$$\alpha(t) = \alpha(0) \cdot \alpha_d^t \cdot \sigma(t) \cdot \sqrt{2\pi}$$

Mit

- $\alpha(t)$ - Lernrate zu Iteration / Zeitpunkt t
- $\alpha(0)$ - Lernrate zu Beginn
- α_d - Lernratenabnahmefaktor
- $\sigma(t) = \sigma_0 \cdot \text{sigma}_d^t$ - Nachbarschaftsradius (Gauß-Standardabweichung) zu Iteration / Zeitpunkt t
- $\sigma(0)$ - Nachbarschaftsradius zu Beginn
- σ_d - Nachbarschaftsradiusabnahmefaktor

$\sigma(t)$ dient zur De-Normalisierung der Gaussfunktion (Nachbarschaft), um den Peak der Gaußfunktion konstant bei 1 zu halten.

Seite 4: <https://www.aanda.org/articles/aa/pdf/2021/01/aa38500-20.pdf>

Wo allerdings die Lernrate abhängig von der Iterationszahl t in der PINK-Implementierung auftaucht ist mir noch nicht ganz klar:

Pink-Git

3 Training

In diesem Kapitel wird beschrieben welche Trainings mit welchen Datensätzen durchgeführt wurden. Dabei wird insbesondere auf die verwendete Parameterwahl eingegangen für die finalen SOM Ergebnisse.

3.1 Datensätze

3.2 Vorverarbeitung der Bilder

3.2.1 Min-Max Skalierung

Durch ‘min-max’-Skalierung werden alle Werte einer Menge \mathcal{M} in den Wertebereich $[0, 1]$ abgebildet. Dies geschieht für jedes Element x der Menge durch folgende Vorschrift:

$$\text{min-max}(x) = \frac{x - \min(\mathcal{M})}{\max(\mathcal{M}) - \min(\mathcal{M})} \quad \forall x \in \mathcal{M}$$

3.3 Parameter

3.4 Trainings mit Radio Bildern

3.5 Trainings mit Multichannel SOMs

3.5.1 Eingrenzung des optischen Channels durch Bounding Box

3.5.2 Eingrenzung des optischen Channels durch eine kovexe Hülle

3.5.3 Eingrenzung des optischen Channels auf minimalen Kreisausschnitt im Zentrum

3.5.4 Gewichtung der Channels

3.5.5 Eingrenzung des optischen Channels durch einen Kreisausschnitt basierend auf einer kovexen Hülle mit

4 Ergebnisse

4.1 Limitationen

4.2 Verbesserungsoptionen

5 Fazit

Abbildungsverzeichnis

1	Übersicht Self-Organizing Map aus An Introduction to Self-Organizing Maps	4
---	---	---

Literaturverzeichnis

- [1] T. W. Shimwell, H. J. A. Röttgering, P. N. Best, W. L. Williams, T. J. Dijkema, F. de Gasperin, M. J. Hardcastle, G. H. Heald, D. N. Hoang, A. Horneffer, H. Intema, E. K. Mahony, S. Mandal, A. P. Mechev, L. Morabito, J. B. R. Oonk, D. Rafferty, E. Retana-Montenegro, J. Sabater, C. Tasse, R. J. van Weeren, M. Brüggén, G. Brunetti, K. T. Chyży, J. E. Conway, M. Haverkorn, N. Jackson, M. J. Jarvis, J. P. McKean, G. K. Miley, R. Morganti, G. J. White, M. W. Wise, I. M. van Bemmél, R. Beck, M. Brienza, A. Bonafede, G. Calistro Rivera, R. Cassano, A. O. Clarke, D. Cseh, A. Deller, A. Drabent, W. van Driel, D. Engels, H. Falcke, C. Ferrari, S. Fröhlich, M. A. Garrett, J. J. Harwood, V. Heesen, M. Hoeft, C. Horellou, F. P. Israel, A. D. Kapińska, M. Kunert-Bajraszewska, D. J. McKay, N. R. Mohan, E. Orrú, R. F. Pizzo, I. Prandoni, D. J. Schwarz, A. Shulevski, M. Sipior, D. J. B. Smith, S. S. Sridhar, M. Steinmetz, A. Stroe, E. Varenius, P. P. van der Werf, J. A. Zensus, and J. T. L. Zwart, “The LOFAR Two-metre Sky Survey. I. Survey description and preliminary data release,” , vol. 598, p. A104, Feb. 2017.
- [2] R. Mostert, K. Duncan, H. Rottgering, K. Polsterer, P. Best, M. Brienza, M. Bruggen, M. Hardcastle, N. Jurlin, B. Mingo, R. Morganti, T. Shimwell, D. Smith, and W. Williams, “Unveiling the rarest morphologies of the lofar two-metre sky survey radio source population with self-organised maps,” *Astronomy Astrophysics*, vol. 645, 11 2020.
- [3] K. C. Chambers, E. A. Magnier, N. Metcalfe, H. A. Flewelling, M. E. Huber, C. Z. Waters, L. Denneau, P. W. Draper, D. Farrow, D. P. Finkbeiner, C. Holmberg, J. Koppenhoefer, P. A. Price, A. Rest, R. P. Saglia, E. F. Schlafly, S. J. Smartt, W. Sweeney, R. J. Wainscoat, W. S. Burgett, S. Chastel, T. Grav, J. N. Heasley, K. W. Hodapp, R. Jedicke, N. Kaiser, R. P. Kudritzki, G. A. Luppino, R. H. Lupton, D. G. Monet, J. S. Morgan, P. M. Onaka, B. Shiao, C. W. Stubbs, J. L. Tonry, R. White, E. Bañados, E. F. Bell, R. Bender, E. J. Bernard, M. Boegner, F. Boffi, M. T. Botticella, A. Calamida, S. Casertano, W. P. Chen, X. Chen, S. Cole, N. Deacon, C. Frenk, A. Fitzsimmons, S. Gezari, V. Gibbs, C. Goessl, T. Goggia, R. Gourgue, B. Goldman, P. Grant, E. K. Grebel, N. C. Hambly, G. Hasinger, A. F. Heavens, T. M. Heckman, R. Henderson, T. Henning, M. Holman, U. Hopp, W. H. Ip, S. Isani, M. Jackson, C. D. Keyes, A. M. Koekemoer, R. Kotak, D. Le, D. Liska, K. S. Long, J. R. Lucey, M. Liu, N. F. Martin, G. Masci, B. McLean, E. Mindel, P. Misra, E. Morganson, D. N. A. Murphy, A. Obaika, G. Narayan, M. A. Nieto-Santisteban, P. Norberg, J. A. Peacock, E. A. Pier, M. Postman, N. Primak, C. Rae, A. Rai, A. Riess, A. Riffeser, H. W. Rix, S. Röser, R. Russel, L. Rutz, E. Schilbach, A. S. B. Schultz, D. Scolnic, L. Strolger, A. Szalay, S. Seitz, E. Small, K. W. Smith, D. R. Soderblom, P. Taylor, R. Thomson, A. N. Taylor, A. R. Thakar, J. Thiel, D. Thilker, D. Unger, Y. Urata, J. Valenti, J. Wagner, T. Walder, F. Walter, S. P. Watters, S. Werner, W. M. Wood-Vasey, and R. Wyse, “The Pan-STARRS1 Surveys,” *arXiv e-prints*, p. arXiv:1612.05560, Dec. 2016.
- [4] K. Polsterer, F. Gieseke, C. Igel, B. Doser, and N. Gianniotis, “Parallelized rotation and flipping invariant kohonen maps (pink) on gpus,” 04 2016.